Prueba Técnica Líder Técnico de IA

Evaluación técnica

Candidato: José Ignacio Garzón Grajales

6. Reto 2 – Visión clásica: resultados, errores y model card

Este reporte consolida los resultados de los cuatro protocolos obligatorios sobre COIL-100 (100 objetos × 72 vistas = 7.200 imágenes) para identificar el objeto, estimar su ángulo (tolerancia mecánica ±10°) y decidir si el robot puede actuar o debe rechazar. Todo ajuste (escalado, PCA, hiperparámetros, calibración y umbrales) usa únicamente las vistas de entrenamiento de cada protocolo; la partición de prueba se evalúa una sola vez.

Resumen ejecutivo

- **A – Interpolación (36 vistas/objeto):** 100.0% de acierto de clase, error angular medio 2.4° y 96.9% de las imágenes dentro de ±10°. La regla de rechazo acepta 45.2% de los casos con 98.1% de agarres seguros.
- **C – Escasez (12 vistas/objeto):** 95.1% de clase y 73.1% dentro de ±10°. La regla de rechazo acepta solo 6.0% de los casos (94.4% seguros entre los aceptados): con tan pocas vistas el sistema no puede certificar el ángulo de la mayoría de las piezas.
- **B – Arco ciego de 60°:** la clase se mantiene (95.1%) pero el ángulo no es recuperable por comparación de vistas (error medio 66.8°, 18.6% dentro de ±10°). El umbral validado acepta apenas 2.2% de los casos y en prueba solo 84.6% de ellos son seguros (objetivo 95%); la política correcta es rechazar la estimación angular y escalar.
- **D – Objetos desconocidos:** el sistema rechaza 99.6% de las vistas de objetos nunca vistos (AUROC 0.951). El costo es un falso rechazo alto en objetos conocidos durante la validación.
- **Hallazgo clave:** una línea base de 1-NN sobre píxeles iguala o supera a HOG+SVM en varios protocolos (C: 97.4% de clase). COIL-100 es un dataset de laboratorio casi resuelto por correspondencia de plantillas; el valor del SVM está en la probabilidad calibrada para decidir, no en la exactitud bruta.

Diseño experimental y control de fuga

- **Pipeline:** descriptores (HOG 64×64 gris + histograma HSV 16/8/8, o píxeles 32×32 RGB) → StandardScaler → PCA(300) → clasificador. Algoritmos comparados: SVM-RBF, regresión logística, Random Forest y KNN (coseno).
- **Protocolos:** A (vistas cada 10°, prueba en el resto), B (arco ciego de 60° por objeto, inicio aleatorio, semilla 42), C (vistas cada 30°), D (10 objetos desconocidos, semilla 42).
- **Validación sin tocar la prueba:** pliegues con la misma geometría que el protocolo (A y C intercalados, B por sectores de 60°) y retención de objetos completos (GroupKFold) para simular desconocidos.
- **Trazabilidad:** semilla 42, huella SHA-256 del dataset **26635cc67c13f12b4010941d0e9e9af0bfda30c52007040377be0caba01c4c4a**, métricas y parámetros registrados en MLflow.

Resultados por protocolo

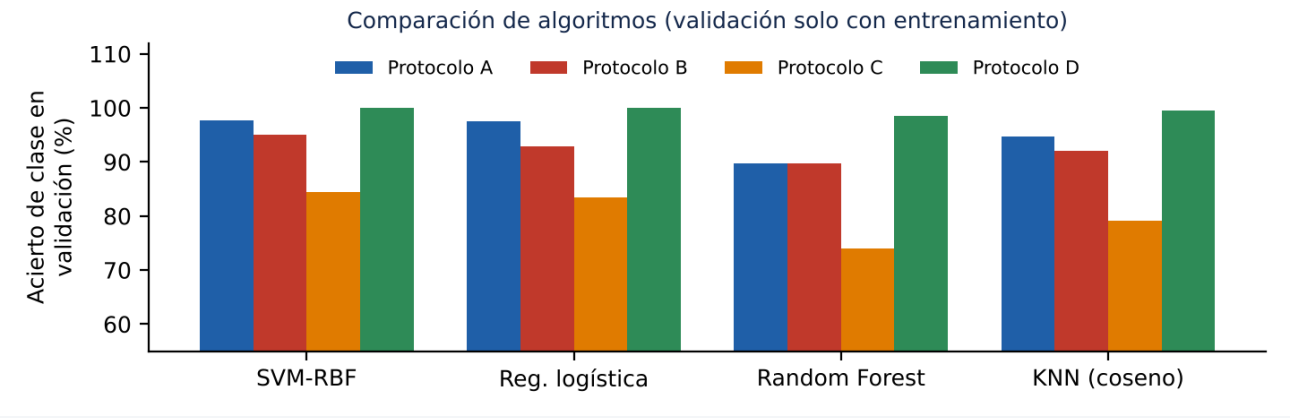
Métrica (prueba)	A Interpolación	B Arco ciego	C Escasez	D Desconocidos
Descriptores elegidos (CV)	HOG + color HSV	Píxeles 32×32	Píxeles 32×32	HOG + color HSV
Vistas de entrenamiento / prueba	3.600 / 3.600	6.000 / 1.200	1.200 / 6.000	6.480 / 720
Acierto de clase en validación (CV)	97.8%	95.1%	84.5%	100.0%
Acierto de clase (prueba)	100.0%	95.1%	95.1%	n/a
Error angular medio / mediana	2.4° / 0.4°	66.8° / 24.9°	15.4° / 5.0°	n/a
Imágenes dentro de ±10°	96.9%	18.6%	73.1%	n/a
Agarre seguro sin rechazo (clase correcta y ±10°)	96.9%	17.3%	71.9%	n/a
Cobertura con rechazo	45.2%	2.2%	6.0%	0.4% aceptados
Agarre seguro entre aceptados	98.1%	84.6%	94.4%	n/a
Precisión@5 (recuperación)	0.844	0.829	0.764	n/a
ECE cruda → calibrada	0.47 → 0.00	0.43 → 0.02	0.76 → 0.02	n/a
AUROC detección de fallo (incertidumbre)	0.94	0.60	0.74	0.95 (conf. de clase)

Los umbrales de rechazo se fijan en validación con objetivos explícitos: ≥99% de acierto de clase entre aceptados, ≥95% de agarres seguros (clase correcta y error ≤10°) y ≤5% de falsa aceptación de desconocidos simulados. «Agarre seguro sin rechazo» es lo que ocurriría si el robot actuara siempre; «entre aceptados» es lo que ocurre con el rechazo activo.

Lectura por protocolo

- **A:** con vistas cada 10° la estimación del ángulo es casi un problema de interpolación entre vecinas. El error medio de 2.4° incluye una cola pequeña: 0.5% de las imágenes con error mayor a 90° (≈13% de los errores mayores a 10° son vistas invertidas). La regla de rechazo, calibrada con la geometría de validación (que ve la mitad de las vistas), es conservadora: acepta 45.2% cuando el modelo podría actuar sobre más.
- **B:** el 29% de las imágenes tiene un error cercano a 180° (vista opuesta) y el 31% supera 90°: en el arco ciego no existe ninguna vista de entrenamiento cercana y la comparación de apariencia confunde el frente con el reverso. No es un problema de hiperparámetros: la información no está en el entrenamiento (ni el 1-NN sobre píxeles pasa de 32% dentro de ±10°). Recomendación operativa: usar solo la clase y pedir una segunda vista o intervención humana para el ángulo.
- **C:** la separación de 30° deja hasta 15° entre la vista real y la más cercana, así que cumplir ±10° exige interpolar. Se logran 73.1% dentro de ±10°; la validación solo con entrenamiento (retener una de cada tres de las 12 vistas) es más escasa que la prueba (hasta 30° de hueco), por lo que los umbrales resultan muy conservadores.
- **D:** sin ver nunca estos 10 objetos, la confianza de clase los separa de los conocidos con AUROC 0.95 y la distancia al vecino más cercano con 0.96.

Selección de algoritmos y descriptores



SVM-RBF gana en validación en los cuatro protocolos; Random Forest queda último en los cuatro protocolos; no se investigó la causa.

Descriptores. La selección entre HOG+color y píxeles 32×32 se hizo por acierto de clase en validación (solo entrenamiento) y, en empate, se prefiere el más simple. Transparencia: los píxeles se añadieron como candidato después de ver que la línea base 1-NN los favorecía en la prueba del protocolo C; el criterio de elección sigue siendo la validación, y la tabla siguiente muestra ambos conjuntos en prueba para que el lector juzgue.

Protocolo	Descriptor	Acc. CV	Clase (prueba)	±10° (prueba)	Elegido por CV
A	HOG + color	97.8%	100.0%	96.9%	sí
A	Píxeles 32×32	97.8%	99.8%	97.2%	
B	HOG + color	90.1%	86.8%	26.2%	
B	Píxeles 32×32	95.1%	95.1%	18.6%	sí
C	HOG + color	74.3%	85.5%	56.7%	
C	Píxeles 32×32	84.5%	95.1%	73.1%	sí

Línea base simple y modelo de referencia moderno

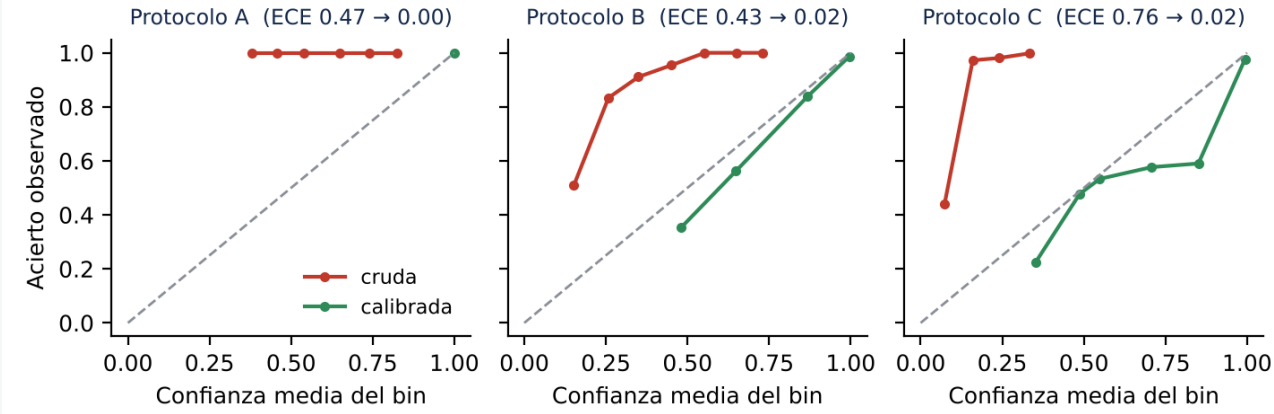
Para justificar la complejidad se comparan tres modelos con las mismas particiones: (1) 1-NN con correlación sobre píxeles 32×32 (sin entrenamiento), (2) el pipeline final SVM, y (3) una CNN pequeña (3 bloques convolucionales, 2 cabezas: clase y (sen, cos) del ángulo; TensorFlow-CPU) como referencia de aprendizaje profundo.

Protocolo	Modelo	Clase	Error medio	±10°	ms / imagen	Ajuste
A	1-NN píxeles	100.0%	6.1°	97.9%	0.19	0.1 s
	Pipeline final (SVM)	100.0%	2.4°	96.9%	—	178 s*
	CNN pequeña	99.8%	27.4°	26.7%	0.73	387 s
B	1-NN píxeles	89.8%	64.5°	32.3%	0.29	0.1 s
	Pipeline final (SVM)	95.1%	66.8°	18.6%	—	701 s*
	CNN pequeña	97.7%	49.8°	16.6%	1.17	497 s
C	1-NN píxeles	97.4%	15.0°	75.4%	0.06	0.1 s
	Pipeline final (SVM)	95.1%	15.4°	73.1%	—	84 s*
	CNN pequeña	99.4%	28.1°	28.6%	0.74	415 s

**Tiempo total del protocolo: comparación de 4 algoritmos con búsqueda de hiperparámetros. OOF. calibración y umbrales (CPU de 2 núcleos). CNN: 153.382 parámetros. 25 épocas (A. B). 91 épocas en C: la primera corrida de C con 25 épocas colapsó (2.0% de clase) por pocos pasos de gradiente y se repitió con un presupuesto fijo de ~1.700 pasos. decisión tomada después de ver ese resultado. Sin ajuste de hiperparámetros ni aumento de datos.*

Conclusión. En **clase**, la CNN es la mejor opción cuando hay pocas vistas (C: 99.4% frente a 95.1% del SVM y 97.4% del 1-NN; B: 97.7% frente a 95.1% y 89.8%), con 153 mil parámetros y ≈1 ms por imagen en CPU. En **ángulo**, que es lo que limita el agarre de ±10°, la CNN con cabeza de regresión (sin ajuste) queda en 27–29% dentro de ±10° en A y C, muy por debajo del 1-NN sobre píxeles (97.9% en A, 75.4% en C) y del pipeline con comparación de vistas. Por tanto el salto de la CNN no se traduce en agarres seguros y no justifica por sí solo su costo de entrenamiento, versionado y latencia en la primera fase; un híbrido (CNN para la clase y comparación de vistas para el ángulo) es la hipótesis a evaluar, no un resultado de este reporte. El 1-NN no necesita entrenamiento ni umbrales calibrados, pero tampoco entrega probabilidades; el SVM las aporta y permite la regla de rechazo.

Calibración, umbrales y decisión del robot



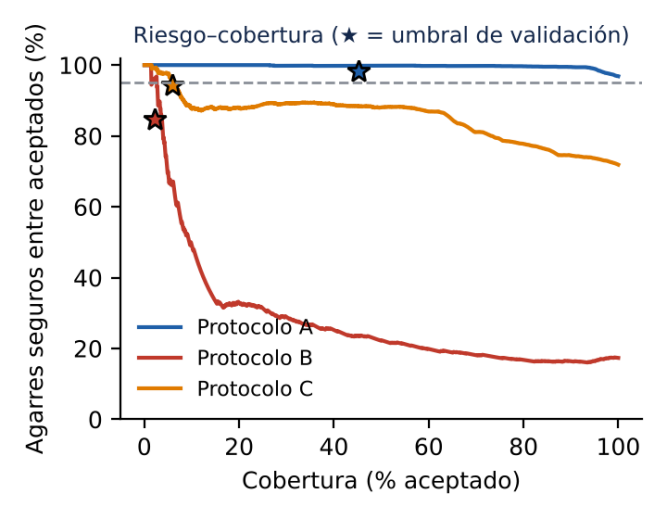
Diagramas de confiabilidad en prueba. La probabilidad cruda del SVM (Platt) es sistemáticamente sub-confiada con muchas clases; la regresión isotónica ajustada solo sobre predicciones fuera de muestra del entrenamiento la corrige. En A la calibrada vale ≈1 porque todos los aciertos son correctos y el ECE degenera a 0; en B y C el ECE residual (0.02–0.09) es la cifra informativa.

Qué recibe el robot

La salida de inferencia es un contrato explícito; el robot nunca recibe un ángulo sin su decisión:

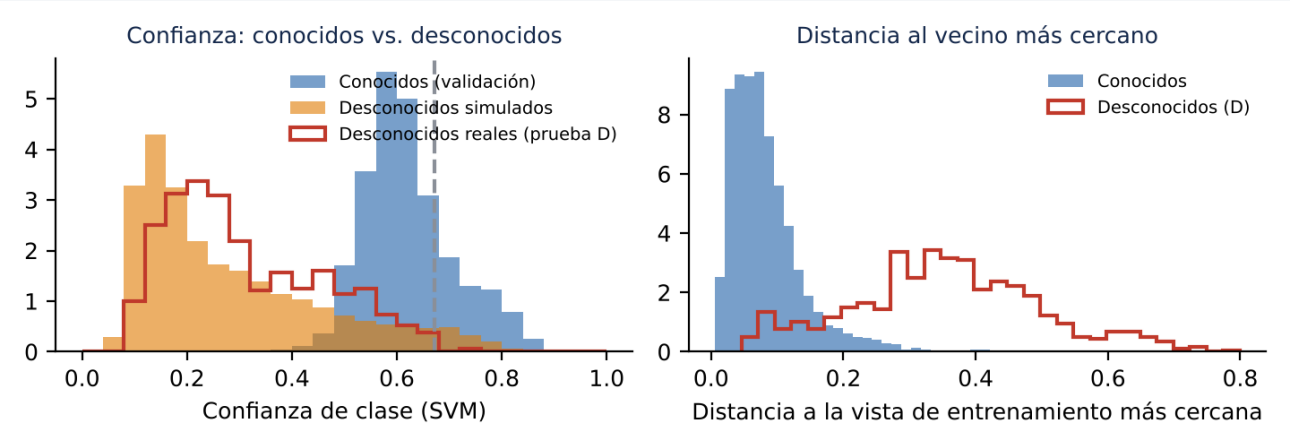
Campo	Contenido
object_id, confidence	Clase predicha y probabilidad calibrada (isotónica).
angle_deg, angle_uncertainty_deg	Ángulo estimado (media circular ponderada de las vistas de la clase) e incertidumbre = desviación circular.
nearest_view_distance	Distancia coseno a la vista de entrenamiento más cercana (señal de objeto fuera de distribución).
decision	**GRASP** si confianza, incertidumbre y distancia cumplen los tres umbrales; **RETRY_VIEW** si falla solo el ángulo; **REJECT / HUMAN** si la clase es dudosa o parece objeto desconocido.
thresholds_version	Versión de umbrales y huella del dataset con que se validaron.

Criterio de aceptación (±10°). Un agarre se considera seguro si la clase es correcta y el error angular circular ≤10°. Los umbrales se eligen para que, entre los casos aceptados, el 95% o más sean seguros en validación. En prueba esto se cumple en A (98.1%) y queda ligeramente por debajo en C (94.4%); en B no se cumple (84.6% con una cobertura de apenas 2.2%). Esto último es un resultado, no un defecto de reporte: el objetivo de ±10° no se puede garantizar con esos datos.



Curva riesgo–cobertura en prueba (diagnóstica, no usada para decidir umbrales): ordenar por incertidumbre eleva la tasa de agarres seguros a costa de cobertura. La estrella marca el punto operativo fijado en validación.

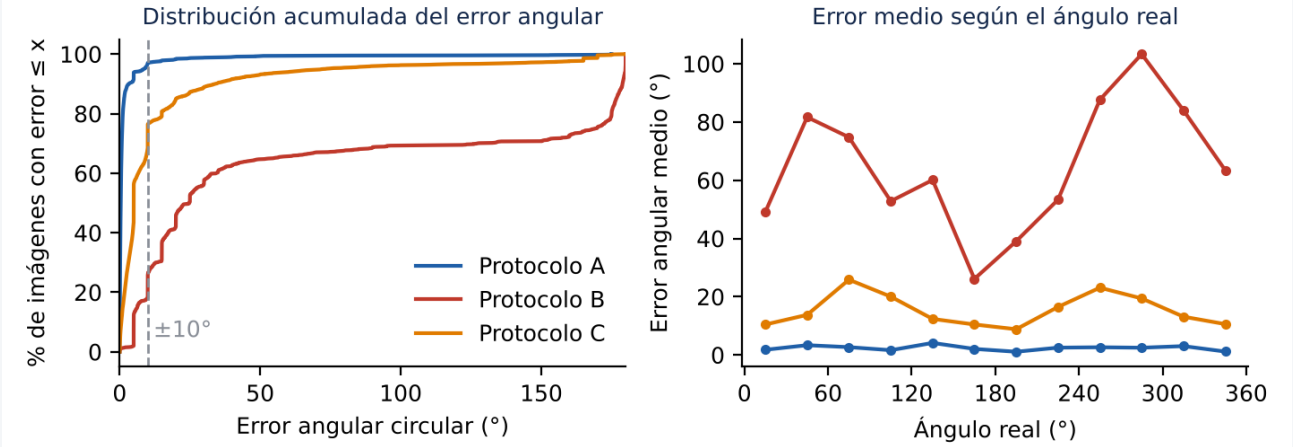
Protocolo D: objetos desconocidos



Izquierda: confianza de clase en vistas conocidas (validación), desconocidos simulados con objetos retenidos del entrenamiento y los 10 desconocidos reales. Derecha: distancia al vecino más cercano.

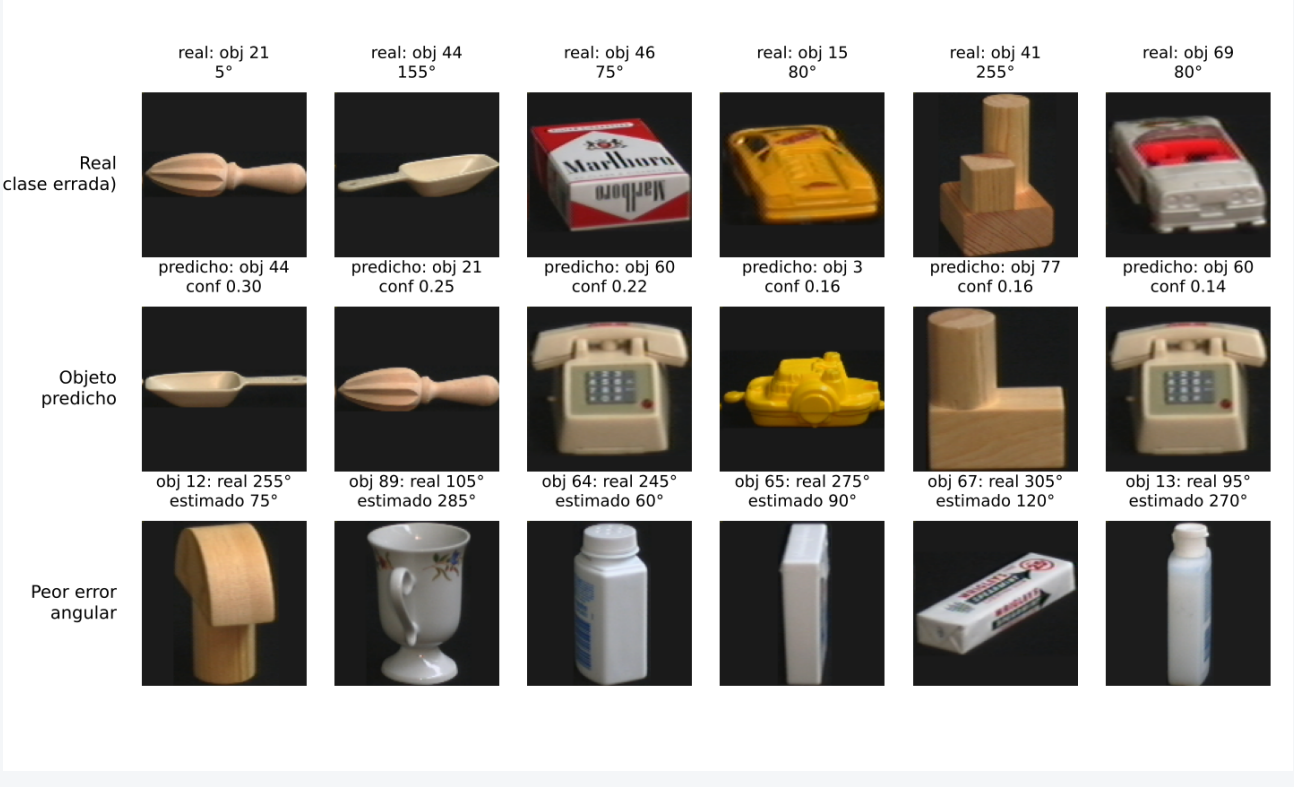
- **Rechazo de desconocidos:** 99.6% con la regla combinada (99.3% solo con la confianza de clase); solo el 0.4% de las vistas desconocidas se aceptaría como un objeto conocido.
- **Costo:** en validación la regla rechaza el 76.4% de las vistas de objetos conocidos. El umbral se fijó para no pasar del 5% de falsa aceptación de desconocidos simulados; si la planta prefiere menos falsos rechazos, la curva ROC (AUROC 0.95) permite mover el punto de operación explícitamente con el costo de cada error.
- **Mejor señal individual:** la distancia a la vista más cercana separa desconocidos con AUROC 0.96 (HOG+color) y 0.99 (píxeles), por encima de la confianza de clase; podría darse mayor peso a esa señal en producción (a validar).

Análisis de errores

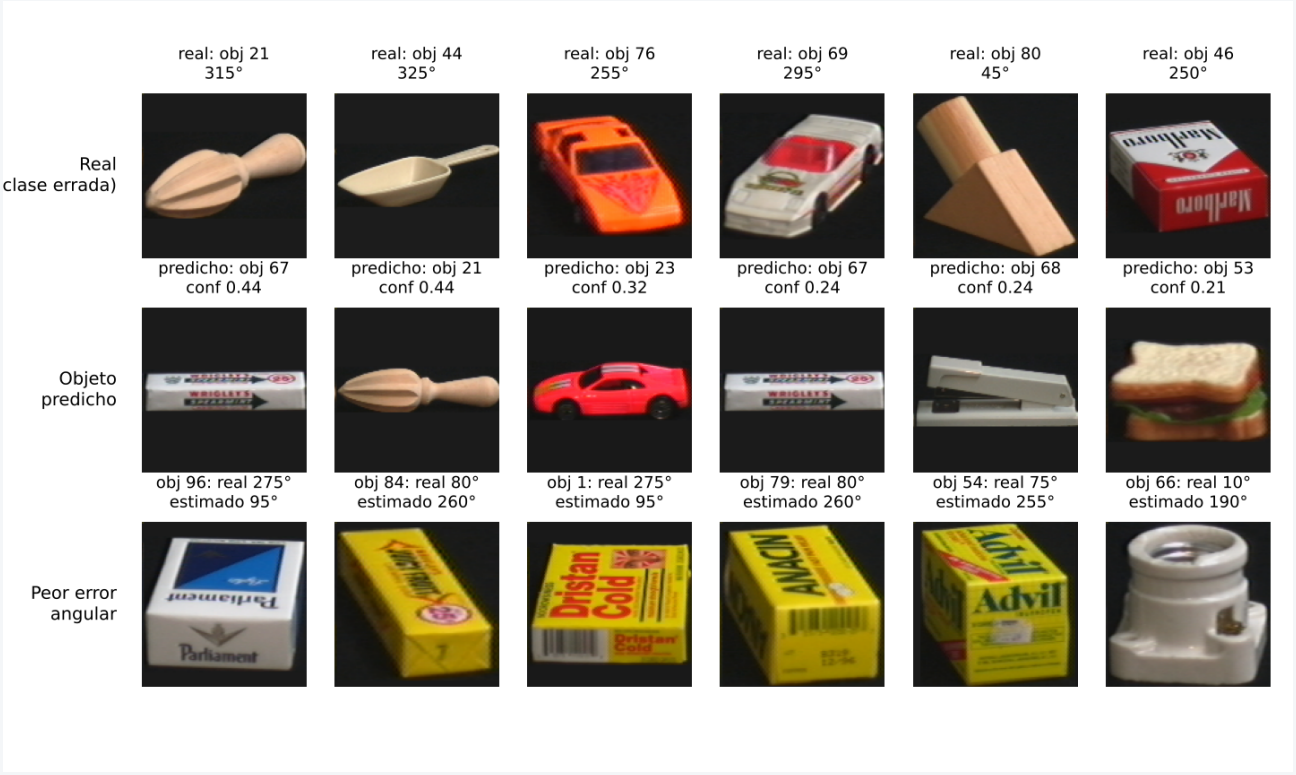


Distribución del error angular por protocolo y error medio según el ángulo real.

- **Confusiones de clase (C):** 44 ↔ 21 (exprimidor y cucharón de madera/crema, 46 y 40 imágenes) concentran la mayor parte del error; con 12 vistas ambos objetos se confunden entre sí (no se investigó la causa). Les siguen el portalámparas (66) y el paquete de chicle (67), ambos clasificados como la grapadora (68).
- **Los errores de clase son de baja confianza:** en C, 292 imágenes con clase errada; solo 3 superan el umbral de confianza y ninguna (0) es aceptada por la regla completa. En B, 59 errores y 0 aceptados. Los errores más confiados de la galería tienen confianza cruda de 0.14–0.30.
- **Ambigüedad angular por simetría:** en C el 10% de los errores mayores a 10° son vistas invertidas (≈180°); tazas con asa, frascos, cajas y piezas de madera casi simétricas se ven iguales de frente y de espalda. Con una sola vista, el ángulo de estos objetos es ambiguo.
- **Clase errada con ángulo bueno:** 0.0% (A), 1.2% (B), 1.2% (C): casi nunca ocurre, por lo que conviene decidir sobre clase y ángulo por separado (GRASP / RETRY_VIEW / REJECT).



Protocolo C. Filas 1–2: errores de clase más confiados (imagen real y un ejemplar del objeto predicho). Fila 3: peores errores angulares con clase correcta.



Protocolo B (arco ciego). Los errores de ángulo se concentran en cajas y paquetes rectangulares, casi simétricos a 180°; los de clase, en objetos que se parecen desde el costado (autos de juguete ↔ paquete de chicle).

Model Card

Campo	Descripción
Modelo	Pipeline clásico: descriptores (HOG+HSV o píxeles 32×32) → StandardScaler → PCA(300) → SVM-RBF con probabilidades (Platt) + calibración isotónica; ángulo por posterior sobre vistas de la clase predicha (media circular); recuperación Top-K por similitud coseno.
Uso previsto	Identificar el SKU y estimar su ángulo (0°–360°) en una estación de pick & pack, entregando al robot una decisión GRASP / RETRY_VIEW / REJECT con incertidumbre.
Datos	COIL-100: 7.200 imágenes, 100 objetos, 72 vistas cada 5°, fondo negro, iluminación fija. SHA-256 26635cc67c13f12b4010941d0e9e9af0bfda30c52007040377be0caba01c4c4a. Sin datos personales.
Evaluación	Cuatro protocolos (A–D), semilla 42, validación geométrica solo con entrenamiento, una única evaluación en prueba. Tolerancia ±10°.
Resultados clave	A: 100.0% clase, 96.9% ±10°. C: 95.1% clase, 73.1% ±10°. B: ángulo no certificable. D: 99.6% de desconocidos rechazados.
Limitaciones	Dataset de laboratorio (fondo negro, sin oclusión, iluminación constante); un solo plano de rotación; objetos casi simétricos son ambiguos a 180°; las cifras no se extrapolan a una banda real sin una evaluación en planta.
Fuera de alcance	Operar sin la regla de rechazo; garantizar ±10° con 12 vistas por objeto (C) o en arcos sin observar (B); reconocer objetos nuevos sin reentrenar; reemplazar por una CNN sin justificar costo y latencia.
Riesgos y mitigación	Agarre fuera de ±10° → regla de rechazo triple (confianza, incertidumbre, distancia) y modo RETRY_VIEW. Deriva por iluminación/suciedad → monitoreo de distancia al vecino más cercano y del ECE; recalibración periódica.
Monitoreo	Tasa de rechazo, distribución de la distancia al vecino más cercano, ECE con etiquetas de auditoría, tasa de reintentos y de intervención humana; alerta ante cambios sostenidos.

Limitaciones del propio estudio

- Las cifras de A y C provienen de una sola partición por protocolo (semilla 42); no se reportan intervalos de confianza entre semillas. Con 7.200 imágenes, un punto porcentual en B equivale a 12 imágenes.
- Los píxeles como descriptor se incorporaron después de observar la línea base en prueba; la elección final se hizo por validación, pero el candidato lo motivó esa observación.
- La CNN es una referencia de tamaño pequeño con épocas fijas, sin ajuste de hiperparámetros ni aumento de datos; no debe leerse como el mejor resultado posible del aprendizaje profundo.
- Los umbrales de rechazo son conservadores porque la validación solo con entrenamiento ve una geometría más escasa que la prueba (en C y B no es posible reproducirla exactamente).

Reproducibilidad

- Notebook **Indra_MLModel_Vision.ipynb** (secciones 9 en adelante) y módulos **lib.py** / **experiment.py**; resultados en **results/**.
- Semilla 42; mismas particiones para todos los modelos; MLflow con parámetros, métricas y huella del dataset por ejecución.